

人工智能引论

1001

目录

I.	聚类分析	3
I.a.	K-means	3
I.b.	DBSCAN	3
I.c.	凝聚型层次聚类法	4
II.	分类	5
II.a.	贝叶斯分类	5
II.b.	决策树	5
II.c.	支持向量机 SVM	6
III.	回归	9
III.a.	线性回归	9
III.b.	逻辑回归	9
IV.	神经网络	11

I. 聚类分析

分类。

划分 / 层次 / 密度：簇之间无交 / 包含关系构成树 / 按密度划分簇

互斥 / 重叠 / 模糊：每个对象属于 $1 / \geq 1 / \varepsilon \in [0, 1]$ 个簇

层次的：凝聚的 / 分裂的：每次合并簇 / 拆分簇

I.a. K-means

划分的，分成 k 个簇。

1. 初始化 k 个质心
2. 对每个点，划分到最近的质心下
3. 更新质心
4. 迭代

误差平方和 $SSE := \sum_{i=1}^k \sum_{x \in S_i} \text{dist}^2(m_i, x)$ 可以证明 SSE 单调不增，若划分变化则 SSE 严格下降，必然停机。但收敛速度不定。

影响因素：

- 规模：高时间复杂度。
- 密度：K-means 假设密度均匀，低密度点会误入高密度簇。最小化 SSE 倾向生成大小相似的簇。
- 形状：K-means 假设数据分布呈球形。对非球形分布不准。

选初始质心：

1. 先选一个：随机 / 全集质心
2. 对后继质心，（从数据点中）选离已选质心最远的。

问题：可能选离群点当质心，代表性下降。

解决：提前删除离群点，后续是否加入？删除很小的簇。

I.b. DBSCAN

密度的

取半径 r ，阈值 Bar 。取邻域 U 为半径为 r 的圆，对点分类：

- 核心点： U 内有 $\geq \text{Bar}$ 个点
- 边缘点： U 内有 $\leq \text{Bar}$ 个点，但其在核心点的邻域内
- 噪音点：都不是

直接密度可达： v 在核心点 u 的邻域内，连边 $u \rightarrow v$

因此，核心点之间构成双向边，只有末端一度点可能为边缘点。在核心点层面上，每次创建的簇两两无交。

1. 从未处理的点中任取一个核心点 u
2. 创建新簇，把 u 与 $u \rightsquigarrow v$ 的 v 划入其中，并标记为处理过
3. 迭代至没有核心点

影响因素：

- ε

- 大：合并簇，区分度差
- 小：大量噪音点
- Bar
 - 大：忽略低密度簇
 - 小：划噪音为簇

I.c. 凝聚型层次聚类法

维护邻近度矩阵。

1. 初始化，每个点成为一个簇
2. 合并最近的两个簇，更新矩阵
3. 迭代

邻近度定义：

- **Min / Max**：取簇间点的距离 Min / Max，又叫单链 / 全链
- **Average**：所有点对距离平均值

问题：

- 局部最优，未必全局最优
- 高时空
- 大数据集分解差

II. 分类

监督：对数据的标注

II.a. 贝叶斯分类

记导致事件 B 的所有原因为 $\{A_n\}$ 。实践上，容易得到原因触发结果的概率，即 $P(B | A_i)$ 。当结果 B 发生时，由此反推 A_i 成为原因的概率。

全概率

$$P(B) = \sum P(B | A_i)P(A_i)$$

贝叶斯

$$P(A_i | B) = \frac{P(A_i \cap B)}{P(B)} = \frac{P(A_i)P(B | A_i)}{\sum P(B | A_i)P(A_i)}$$

极大后验假设 Maximum A Posteriori (MAP): 找主要原因

$$\begin{aligned} h &= \arg \max_i P(A_i | B) \\ &= \arg \max_i \frac{P(A_i)P(B | A_i)}{P(B)} \\ &= \arg \max_i P(A_i)P(B | A_i) \end{aligned}$$

朴素贝叶斯分类:

- 数据集 $\{\mathbf{x}, y\}$: $\mathbf{x} = (a_1, \dots, a_n)$ 为一列事件/属性, y 为观测到的结果。
- 测试: 现在发生了 $\mathbf{x}'$, 求最可能的结果 y' 。(仿佛 y 导致 $\mathbf{x}$, 找 y)

$$\begin{aligned} y' &= \arg \max_y P(y | \mathbf{x}') \\ &= \arg \max_y P(y)P(\mathbf{x}' | y) \\ &= \arg \max_y P(y) \prod P(a_i' | y) \quad \text{独立性假设} \end{aligned}$$

从数据中估计 $P(y), P(a_i | y)$ 都容易, 直接估计 $P(\mathbf{x} | y)$ 面临数据不足的问题。

II.b. 决策树

本质 K-D Tree。

1. 取一个性状, 按相对性状对数据分类
2. 对每一类递归, 递归关系构成决策树

优先取分类效果好的特征进行分类。

优劣评价标准: 信息增益。熵减越多, 分类效果越好。

P_i 是对最终结果的概率估计, 这是唯一关心的性状, 其它性状只是辅助用于分类。

- 熵 $H(S) = -\sum P_i \log P_i$
- 条件熵 $H(S | A) = \sum \frac{S_i}{S} H(S_i)$
- 信息增益 $g(S, A) := H(S) - H(S | A)$

问题：过拟合。分类过细。

记 $sz(u)$ 为 u 子树内的样本数， $N(T)$ 为决策树 T 的叶子数量，取 α 为一调节系数，定义损失函数

$$C(T) = \underbrace{\sum_{u \in \text{leaf}} sz(u)H(u)}_{\text{限制分类误差}} + \underbrace{\alpha N(T)}_{\text{限制树大小}}$$

目标：减小 $C(T)$ 。

优化：

- 剪枝：
 - 调整：计算 $C(T)$ 增量
 - 设阈值：限制 Max-Dep / Min-Size
- 调参 α
- 决策树森林：组合多棵树
- 提前分类，对每一类构建决策树。

优点：不受特征尺度影响；支持多样数据类型；支持多变量预测

缺点：过拟合；不稳定，结构受数据微扰影响大；倾向于选择具有更多类别的特征

II.c. 支持向量机 SVM

Support Vector Machine. SVM

用超平面划分点集，本质二分类。

II.c.a. 线性 SVM

超平面 $\mathbf{n} \cdot \mathbf{x} + b = 0$ ，其中 $\mathbf{w}$ 为法向量， $b \in \mathbb{R}$ 为常数。

点到超平面距离

$$\text{Dist}(\mathbf{x}) = \left| (\mathbf{x} - \mathbf{x}_0) \cdot \frac{\mathbf{w}}{\|\mathbf{w}\|} \right| = \frac{|\sum a_i x_i + b|}{\sqrt{\sum a_i^2}} = \frac{|\mathbf{w} \cdot \mathbf{x} + b|}{\|\mathbf{w}\|}$$

给定点集，找一张超平面 α ，最大化到平面最小距离 $\max\{\min \text{Dist}(\mathbf{x})\}$ 。记这最小距离为 d ，则 $\text{Dist} = d$ 的点称支持向量，其撑起了分界线。任一点代入 α 方程，结果正负代表位于平面的上/下方，实现了二分类。

$$f(\mathbf{x}) = \text{sgn}(\mathbf{w} \cdot \mathbf{x} + b)$$

训练集 $T = \{(\mathbf{x}_n, y_n)\}$ ， $y_i \in \{1, -1\}$ 。 y_i 为标记（上方/下方），引入标记以免去 sgn 函数。

函数间隔： $\hat{\gamma} := y_i(\mathbf{w} \cdot \mathbf{x}_i + b)$

归一化 $\gamma := \frac{\hat{\gamma}}{\|\mathbf{w}\|} = y_i \left(\frac{\mathbf{w}}{\|\mathbf{w}\|} \cdot \mathbf{x}_i + \frac{b}{\|\mathbf{w}\|} \right)$

目标：

$$\begin{aligned} \max_{\mathbf{w}, b} \gamma \quad & s.t. \ y_i \left(\frac{\mathbf{w}}{\|\mathbf{w}\|} \cdot \mathbf{x}_i + \frac{b}{\|\mathbf{w}\|} \right) \geq \gamma \\ \Leftrightarrow \max_{\mathbf{w}, b} \frac{\hat{\gamma}}{\|\mathbf{w}\|} \quad & s.t. \ y_i (\mathbf{w} \cdot \mathbf{x}_i + b) \geq \hat{\gamma} \end{aligned}$$

令 $\hat{\gamma} = 1$ ，即人为划定一个间隔带。归一化的 γ 即 Dist，但实际计算中 $\hat{\gamma}$ 更容易。 $\frac{1}{2}$ 的系数使求导后常数归一。

$$\begin{aligned} \Leftrightarrow \max_{\mathbf{w}, b} \frac{1}{\|\mathbf{w}\|} \quad & s.t. \ y_i (\mathbf{w} \cdot \mathbf{x}_i + b) \geq 1 \\ \Leftrightarrow \min_{\mathbf{w}, b} \frac{1}{2} \|\mathbf{w}\|^2 \quad & s.t. \ y_i (\mathbf{w} \cdot \mathbf{x}_i + b) \geq 1 \end{aligned}$$

希望将不等式转化为等式处理，引入松弛变量 $\{\xi_n\}$ ，定义损失函数

$$L = \frac{1}{2} \|\mathbf{w}\|^2 + C \sum \xi_i \quad s.t. \ y_i (\mathbf{w} \cdot \mathbf{x}_i + b) = 1 - \xi_i$$

C 为惩罚因子，利用拉格朗日乘数法可解。

II.c.b. 非线性 SVM

希望构造一个映射 ϕ ，使得 $\phi(\mathbf{x})$ 在高维空间线性可分。

一般将拉格朗日函数对偶处理，对偶后涉及 $\phi(\mathbf{x})$ 的内积。一般地，显示给出 ϕ 较困难，但只需要计算其内积。因此，若存在简单函数 $K(\mathbf{u}, \mathbf{v}) \equiv \phi(\mathbf{u}) \cdot \phi(\mathbf{v})$ ，用 K 代替即可。 K 称核函数。

II.c.c. 多分类

样本本身为多类别，用二分类拟合。

- 一对一

共 m 个类别。对 $\binom{m}{2}$ 对组合分别构建 SVM。预测时遍历所有 SVM，按划分投票，票数最多的一类为预测结果。

效率低，效果好。

- 一对多

每次取一个类别，规定其为正类，其它 $m - 1$ 个为负类。建 m 个 SVM。

分类器少，但正负样本数不平衡。

解决：对正负样本设不同的惩罚因子。

- 层次法

建二叉树。

效率高，但误差累积。

II.c.d. 总结

- 优点

能处理高维问题；非线性问题。

泛化能力强，因其最小化结构风险而非经验风险。（简单地，对过拟合有限制。）
应用场景广。

- 缺点

计算成本高；调参难。

对异常值敏感。

III. 回归

III.a. 线性回归

损失函数：评价单样本误差。e.g. 平方和损失 $L(\mathbf{x}) := \frac{1}{2}(h(\mathbf{x}) - y)^2$

代价函数：评价训练集平均误差。e.g. 残差平方和 $J := \frac{1}{2n} \sum (h(\mathbf{x}) - y)^2$

目标函数：代价和正则化。 $f = J(\mathbf{w}) + \lambda \Omega(\mathbf{w})$ ，引入 λ 来限制过拟合， Ω 为针对结构的函数。

取回归函数 $h(\mathbf{x}) = \mathbf{w} \cdot \mathbf{x} + b$ ，仅以代价函数为目标函数举例。

- 最小二乘法

无约束极值，求偏导令为零。

对 $\mathbf{x} \in \mathbb{R}$ 的情景

$$w^* = \frac{\frac{1}{n} \sum x_i y_i - \bar{x} \bar{y}}{\frac{1}{n} \sum x_i^2 - \bar{x}^2}$$
$$b^* = \bar{y} - w^* \bar{x}$$

适合数据集小，维数低。

- 梯度下降

设学习率 α ，迭代 $w \leftarrow w - \alpha \frac{\partial J}{\partial w}$ ， $b \leftarrow b - \alpha \frac{\partial J}{\partial b}$

广泛，但步长 α 设置影响迭代速度。

评价指标：

- 平均绝对误差 $\text{MAE} := \frac{1}{n} \sum |y_i - \hat{y}_i|$
平均绝对百分比误差 $\text{MAPE} := \frac{100}{n} \sum \left| \frac{y_i - \hat{y}_i}{y_i} \right|$
- 均方误差 $\text{MSE} := \frac{1}{n} \sum (y_i - \hat{y}_i)^2$
- R^2 评价指标 $R^2 := 1 - \frac{\sum (y_i - \hat{y}_i)^2}{\sum (y_i - \bar{y})^2}$ ，越大越好

广义线性回归：对 y 做映射，使得能线性回归。e.g. $\ln y = \mathbf{w} \cdot \mathbf{x} + b$

条件：映射的函数单调可微。

III.b. 逻辑回归

用线性回归做二分类，本质并非回归。

用概率分类，按 $> 0.5 / < 0.5$ 分类。为此需将 $\mathbb{R} \rightarrow [0, 1]$ ，取 S 型函数 (Sigmoid Function)。其关于 $(0, 0.5)$ 对称，在左右两侧迅速减/增至 0/1。

$$f(x) = \frac{1}{1 + e^{-x}}$$

预期值，即当作 $P(\mathbf{x})$ 。

$$h(\mathbf{x}) = f(\mathbf{w} \cdot \mathbf{x} + b)$$

应用极大似然估计 MLE，求 $\mathbf{w}, b$ 使得在此分布下 $P(\mathbf{y} = (y_1, \dots, y_n))$ 最大，其中样本 $y_i \in \{0, 1\}$ 。

$$\begin{aligned}\max_{\mathbf{w}, b} L(\mathbf{w}, b) &:= \prod P(y_i | x_i) = \prod [h(\mathbf{x}_i)]^{y_i} [1 - h(\mathbf{x}_i)]^{1-y_i} \\ \Leftrightarrow \max_{\mathbf{w}, b} \ln L(\mathbf{w}, b) &= \sum [y_i \ln h(\mathbf{x}_i) + (1 - y_i) \ln(1 - h(\mathbf{x}_i))] \\ \Rightarrow \min_{\mathbf{w}, b} J(\mathbf{w}, b) &:= -\frac{1}{n} \ln L(\mathbf{w}, b)\end{aligned}$$

故取损失函数 $L(y, \hat{y}) = y \ln \hat{y} + (1 - y) \ln(1 - \hat{y})$

代价函数 $J(\mathbf{w}, b) = -\frac{1}{n} \sum L(y, \hat{y})$

沿用梯度下降，推导略

$$\begin{aligned}w &\leftarrow w - \alpha \frac{1}{n} \sum x_i [h(x_i) - y_i] \\ b &\leftarrow b - \alpha \frac{1}{n} \sum [h(x_i) - y_i]\end{aligned}$$

评价指标：

TP: True Positive 真阳性 FN: False Negative 假阴性

FP: False Positive 假阳性 TN: True Negative 真阴性

- 准确率 $\text{Accuracy} := \frac{\text{TP} + \text{TN}}{\text{TP} + \text{FN} + \text{FP} + \text{TN}}$
- 精准率 $\text{Precision} := \frac{\text{TP}}{\text{TP} + \text{FP}}$
- 召回率 $\text{Recall} := \frac{\text{TP}}{\text{TP} + \text{FN}}$
- $F_{\text{score}} := (1 + \beta^2) \frac{\text{Precision} \cdot \text{Recall}}{\beta^2 \cdot \text{Precision} + \text{Recall}}$ ，为精准率与召回率的加权调和平均。

精准率与召回率都是对钦定的正类而言。

- 优点

形式简单，可解释性好；易于并行；资源占用小，尤见于内存；方便输出结果调整。

- 缺点

表达能力不强；准确率不高；处理非线性预测难。

IV. 神经网络